


Echo: Decoupling Inference and Training for Large-Scale RL Alignment on Heterogeneous Swarms

Jerry Xiao @ Gradient

强化学习简要介绍

强化学习 (RL) 对于语言模型 (LLM) 的对齐至关重要。尤其人类反馈强化学习 (RLHF) 及其衍生方法 (PPO, RLHF, GRPO, DPO, etc.) 取得成功后, RL已成为将数十亿、百亿参数的语言模型与人类意图对齐的主要机制。当前比较流行的框架有verl, slime等。这里以GRPO为例:



但该方案存在的一些潜在问题:


- 推理和优化紧密耦合
- 对异构加速器的支持很少

目前的方案存在哪些可以被优化的问题

1. 我们能否在保持收敛性的同时将 **rollout** 生成和优化解耦？
2. 如何在 *多数据多计算* 工作负载下协调异构计算节点，避免利用率过低？
3. 哪些方法能够实现去中心化推理集群和训练集群之间可扩展且高效的通信？

Parallax: Efficient Distributed LLM Inference on Heterogeneous Hardware

分布式大语言模型（LLM）推理框架，旨在解决异构、去中心化硬件（从数据中心 GPU 到消费级显卡以及Apple Silicon Mac）上高效运行 LLM 的问题。



框架构成：

Scheduling 调度层：

- 模型层分配 + 请求路由，完全“硬件无关”

Executor 执行层：

- 承上启下，既统一逻辑，又针对硬件做优化

Swarm 集群层：

- 动态扩容 + 负载均衡，让新节点能“即插即用”，老节点能“自动减负”

Parallax: Efficient Distributed LLM Inference on Heterogeneous Hardware: <https://gradient.network/parallax.pdf/>

./ gradient

Parallax: Efficient Distributed LLM Inference on Heterogeneous Hardware

Table 1: Performance comparison of PARALLAX vs. Petals on Qwen2.5-72B-Instruct-GPTQ-Int4 model.

Framework	Input Config	E2E Lat. (s)	TTFT (s)	ITL (ms)	Output TP (tok/s)
PARALLAX (2 × RTX 5090)	1×4K	46.6	5.0	40.7	22.0
	1×8K	52.7	9.9	41.8	19.4
	1×16K	64.6	20.6	43.0	15.8
	4×1K	46.8	3.4	42.5	87.5
	8×1K	62.4	7.9	53.3	131.3
PARALLAX (RTX 5090 + Mac M4 Pro)	1×1K	175.2	14.4	157.2	5.8
	1×4K	242.4	64.9	173.6	4.2
	4×1K	544.5	65.1	468.7	7.5
Petals (2 × RTX 5090)	1×4K	143.5	14.4	216.5	7.1

Table 2: Performance evaluation of PARALLAX on Qwen3-235B-A22B-GPTQ-Int4 model.

Framework	Input Config	E2E Lat. (s)	TTFT (s)	ITL (ms)	Output TP (tok/s)
PARALLAX (6 × RTX 5090)	1×1K	65.5	2.9	61.2	15.6
	1×4K	75.1	13.4	60.3	13.6
	4×1K	99.3	8.7	88.6	41.2
PARALLAX (RTX 5090 + 3 × Mac M4 Pro)	1×1K	104.9	8.1	94.6	9.8
	1×4K	150.0	34.2	113.2	6.8
	4×1K	320.4	30.2	283.6	12.8

框架特点:

- 1. 基于 P2P 的流水线并行
- 2. 异构硬件的统一编排
 - 硬件无关的调度层
 - 硬件特异性的执行层
- 3. 性能优化技术
 - 动态 KV 缓存管理
 - 连续批处理
 - 优化的通信协议

Parallax: Efficient Distributed LLM Inference on Heterogeneous Hardware: <https://gradient.network/parallax.pdf/>

Code Repo: 9月份开源，欢迎大家来一起build!

Echo: Decoupling Inference and Training for Large-Scale RL Alignment on Heterogeneous Swarms

框架特点:

1. 双集群:


- 训练集群: NVLink A100/H100 + VERL算法库
- 推理集群: 分布式消费级显卡 + Parallax

2. 协调器:


- 可调同步间隔 + 数据配额

3. 高效通信


- 模型分片 (并行从多节点下载)
- 模型参数压缩




Echo: Decoupling Inference and Training for Large-Scale RL Alignment on Heterogeneous Swarms



(a) Sokoban w/ Qwen3-4B



(b) Math w/ Qwen2.5-7B



(c) K&K w/ Qwen3-32B

- 完全对齐中心化RL训练过程 step-by-step

Echo: Decoupling Inference and Training for Large-Scale RL Alignment on Heterogeneous Swarms

Table 1: Model performance on Sokoban task

Model	Success Rate (%)
Qwen3-4B	21.8
Qwen3-4B-ECHO(GRPO)	34.0
Qwen3-30B-A3B-Thinking-2507	72.75
Qwen3-30B-A3B-Thinking-2507-ECHO(GRPO)	82.20
Deepseek-R1	75.75
Qwen3-235B-A22B-Thinking-2507	79.68
gpt-oss-120b	79.69

Table 2: Model performance on math reasoning tasks. For AIME and AMC, the results are avg.@32

Model	AIME24	AIME25	AMC	MATH-500	OlympiadBench	Minerva	Avg.
Qwen2.5-7B	2.7%	1.9%	22.0%	44.6%	19.7%	20.9%	18.6%
Qwen2.5-32B	5.3%	2.1%	27.9%	62.4%	25.4%	33.5%	26.1%
Qwen2.5-7B-ECHO(GRPO)	13.1%	6.9%	45.6%	75.4%	37.0%	50.7%	38.1%

Table 3: Model performance on K&K logic puzzle task across different degrees of difficulty

Model	2	3	4	5	6	7	8
Qwen3-32B	0.98	0.99	0.98	0.99	0.98	0.96	0.95
Deepseek-R1	1.00	0.97	0.95	0.93	0.91	0.93	0.91
o3-mini-high	1.00	1.00	1.00	1.00	0.99	0.98	0.98
o4-mini	1.00	1.00	0.96	0.94	0.97	0.93	0.87
Qwen3-32B-ECHO(GRPO w/ Lora)	0.99	1.00	1.00	1.00	0.99	1.00	0.99

Lattica: Distributed P2P Communication Library


Lattica 是一个支持多应用场景的去中心化P2P通信框架：

专为大模型复杂**动态**网络环境设计，其目标包含：

1. 增加网络节点接入容量
2. 优化网络通信性能
3. 提升网络通信稳定性

支持特性：

- 多协议支持：TCP、QUIC、Websocket、WebRTC
 - 复杂网络环境优化：多协议NAT穿透、路由优化策略
 - 多场景支持：去中心化AI训练推理、CDN等
 - 通信安全：节点身份验证、数据签名加密
-
- 传播理性数据：（ 30B 60G数据 ）1个训练→ 30个推理
 - 条件：跨洲公网 1Gbit/s 带宽约 60 MB/s，单点传输 17分钟
 - 1训练，30推理节点：
 - 1 → 5 85分钟
 - 5 → 25 85分钟
 - Total 170分钟



Future Work on Echo

1. 模型更新方式

2. 通信频率

$$t_{train} - t_{infer} > \Delta_{max}$$

3. 通信参数

top K 、 压缩、量化、剪枝

4. 数据端解偶

./ gradient

Building the **fastest** and **easiest-to-use** machine learning stack that runs on fully distributed systems!

https://x.com/Gradient_HQ

<https://gradient.network/>

<https://careers.gradient.network/>

